

АННОТАЦИЯ

Курсовая работа посвящена разработке модели градиентного бустинга для выявления клиентов с повышенным кредитным риском на основе набора данных UCI Credit Card Default Dataset.

Объектом исследования является процесс оценки кредитного риска клиентов банка на основе исторических данных об их финансовом поведении.

Предметом исследования выступают методы статистической обработки данных и алгоритмы машинного обучения, применяемые для прогнозирования вероятности дефолта заемщиков.

В работе рассмотрены теоретические основы статистического анализа данных, возможности языка программирования R и программного обеспечения Glarus BI. Выполнен исследовательский анализ данных, проведены корреляционный анализ, проверка статистических гипотез и построение моделей машинного обучения для классификации клиентов по уровню кредитного риска.

Практическая часть выполнена на основе открытого набора данных UCI Credit Card Default Dataset, содержащего сведения о 30 000 клиентах банка. Проведена предварительная обработка данных, выполнено сравнение моделей классификации и анализ качества прогнозирования.

Результаты исследования могут быть использованы для автоматизации процессов кредитного скоринга и поддержки принятия решений в финансовых организациях.

Ключевые слова: кредитный риск, дефолт, кредитный скоринг, машинное обучение, градиентный бустинг, логистическая регрессия, классификация, анализ данных, язык R, Glarus BI.

Курсовая работа изложена на 65 страницах, содержит 25 рисунков, 7 таблиц, 5 приложения и 21 источника литературы.

Содержание

<i>Введение</i>	5
<i>Глава 1. Теоретическая часть</i>	7
1.1 Описание предметной области	7
1.2 Основные методы статистической обработки данных	8
1.3 Язык программирования R и его возможности для статистического анализа	12
1.4 Программное обеспечение Glarus BI	13
1.5 Сравнение возможностей R и Glarus BI	15
1.6 Предварительные выводы по главе 1	17
<i>Глава 2. Практическая реализация исследования</i>	19
2.1 Описание используемых данных	19
2.2 Исследовательский анализ данных	21
2.3 Применение методов статистического анализа	28
2.4 Машинное обучение в анализе данных	35
2.5 Визуализация данных	45
2.6 Выводы по главе 2	50
<i>Глава 3. Автоматизация и отчетность в анализе данных</i>	51
3.1 Генерация отчетов в R	51
3.2 Формирование интерактивных отчетов в Glarus BI	52
3.3 Сравнение инструментов R и Glarus BI	52
3.4 Предварительные выводы по главе 3	53
<i>Заключение</i>	53
<i>Список источников</i>	54
<i>Приложения</i>	57

Введение

Тема данной курсовой работы посвящена разработке регрессионной модели градиентного бустинга и анализу ее сходимости применительно к решению задачи выявления повышенного кредитного риска на примере набора данных о клиентах банка. Актуальность этой темы обусловлена тем, что в современном мире банки и финансовые организации сталкиваются с необходимостью быстро и точно оценивать вероятность невозврата кредитов. Ошибки в такой оценке могут приводить к серьезным финансовым потерям. Традиционные статистические методы, такие как логистическая регрессия, часто имеют ограничения при работе со сложными и нелинейными зависимостями в данных о клиентах. Поэтому возникает потребность в более мощных и гибких алгоритмах машинного обучения, одним из которых является градиентный бустинг. Этот метод зарекомендовал себя как один из самых эффективных для решения задач классификации и регрессии, в том числе в области скоринга.

Объектом данного исследования является процесс оценки кредитного риска на основе исторических данных о клиентах банка. Предметом исследования выступает регрессионная модель, построенная на основе алгоритма градиентного бустинга, а также процесс её обучения, называемый сходимостью, то есть то, как быстро и стабильно модель улучшает свои прогнозы на каждом шаге обучения.

Целью курсовой работы является разработка модели градиентного бустинга для выявления клиентов с повышенным кредитным риском и проведение анализа сходимости этой модели в зависимости от её основных параметров. Для достижения этой цели необходимо решить несколько задач. Во-первых, требуется изучить теоретические основы градиентного бустинга и понять, как работает механизм повышения точности прогнозов за счет последовательного построения деревьев решений. Во-вторых, нужно провести

подготовку и первичный анализ имеющегося набора данных о клиентах банка, включая обработку пропусков и преобразование категориальных признаков. В-третьих, необходимо реализовать модель градиентного бустинга с использованием языка программирования R и подходящих библиотек. Наконец, следует оценить качество построенной модели на тестовых данных и интерпретировать полученные результаты.

Методологическую основу работы составляют методы машинного обучения, в частности ансамблевые методы и градиентный бустинг, а также методы статистической обработки данных и визуализации. Инструментальной базой для выполнения всех этапов анализа послужит среда программирования R.

1 Глава Теоретическая часть

1.1 Описание предметной области

1.1.1 Значимость анализа данных в рассматриваемой области.

В банковской сфере анализ данных играет ключевую роль при решении задачи оценки кредитного риска. Без применения статистических методов банк не может объективно определить, насколько вероятен возврат выданного кредита. На основе исторических данных о клиентах строятся модели, которые предсказывают вероятность просрочки платежа. Это позволяет автоматизировать принятие решений, снизить убытки от невозвратов и ускорить обслуживание клиентов. В данной курсовой работе решается именно такая задача: предсказание повышенного кредитного риска с помощью градиентного бустинга.

1.1.2 Основные типы данных (числовые, категориальные, временные ряды)

Задачах анализа кредитного риска используются данные разных типов. Числовые данные включают возраст клиента, размер кредитного лимита, суммы ежемесячных платежей и счетов. Такие данные можно обрабатывать арифметическими операциями. Категориальные данные представляют собой признаки с ограниченным набором значений: пол, семейное положение, уровень образования, статус оплаты за предыдущие месяцы. Перед применением статистических моделей категориальные переменные кодируются в числовой

вид. Временные ряды в данной задаче — это история платежей клиента за несколько предыдущих месяцев, которая позволяет отследить динамику изменения платежной дисциплины

1.1.3 Ключевые задачи статистического анализа (прогнозирование, выявление закономерностей, оптимизация процессов)

В рамках курсовой работы решаются три ключевые задачи статистического анализа. Прогнозирование заключается в том, чтобы для каждого клиента предсказать вероятность дефолта в следующем месяце. Выявление закономерностей направлено на поиск скрытых связей между характеристиками клиента и его надежностью. Например, по результатам анализа можно определить, какие признаки сильнее всего влияют на кредитный риск. Оптимизация процессов позволяет на основе построенной модели автоматизировать рассмотрение кредитных заявок, снижая нагрузку на сотрудников банка и ускоряя принятие решений.

1.2 Основные методы статистической обработки данных

1.2.1 Описательная статистика (среднее, медиана, мода, дисперсия)

Описательная статистика используется для первичного обобщения данных и понимания их структуры. Среднее значение показывает средний уровень признака, например, средний кредитный лимит всех клиентов. Медиана отражает центральное значение выборки и менее чувствительна к выбросам, поэтому её применение особенно полезно при наличии аномально высоких или

низких значений. Мода показывает наиболее часто встречающееся значение и удобна для анализа категориальных данных, например, самого распространённого уровня образования среди клиентов. Дисперсия и стандартное отклонение характеризуют разброс значений вокруг среднего: чем выше эти показатели, тем более неоднородной является выборка. Совместное использование этих характеристик позволяет составить первое представление о данных и выявить потенциальные проблемы, такие как сильная асимметрия или наличие выбросов.

1.2.2 Методы проверки гипотез

Методы проверки статистических гипотез позволяют формально оценить, являются ли наблюдаемые различия между группами случайными или статистически значимыми. Нулевая гипотеза обычно утверждает отсутствие различий или связей, а альтернативная — наличие таковых. Уровень значимости задаёт порог для принятия решения, а p -value показывает вероятность ошибочного отклонения нулевой гипотезы. Т-тест применяется для сравнения средних значений двух групп, например, для проверки различий в кредитном лимите между мужчинами и женщинами. Дисперсионный анализ (ANOVA) используется при сравнении трёх и более групп. Хи-квадрат тест предназначен для анализа категориальных данных и проверки независимости признаков, например, связи между полом клиента и фактом возникновения дефолта. Корректное применение этих методов обеспечивает объективность и воспроизводимость выводов.

1.2.3 Корреляционный анализ и регрессионное моделирование

Корреляционный анализ позволяет оценить силу и направление связи между двумя переменными. Коэффициент корреляции Пирсона измеряет линейную зависимость и принимает значения от -1 до 1, где знак указывает направление связи. Для нелинейных зависимостей или данных с выбросами чаще применяется коэффициент ранговой корреляции Спирмена. Регрессионное моделирование идёт дальше и позволяет не только выявить связь, но и описать её в виде математической функции. Простая линейная регрессия описывает зависимость между двумя переменными, например, между возрастом клиента и его кредитным лимитом. Множественная линейная регрессия включает несколько независимых переменных и позволяет оценить совокупное влияние различных факторов на результирующий показатель. Для задач бинарной классификации, где результат принимает только два значения (например, дефолт или его отсутствие), применяется логистическая регрессия, которая оценивает вероятность наступления события.

1.2.4 Методы кластеризации и классификации(если применимо к работе)

Методы классификации и кластеризации относятся к задачам машинного обучения с учителем и без учителя соответственно. Классификация применяется в тех случаях, когда заранее известны метки классов, и модель обучается на размеченных данных. В данной курсовой работе решается именно задача классификации: необходимо отнести клиента к группе надежных заемщиков или к группе с повышенным кредитным риском. Градиентный бустинг является одним из наиболее эффективных методов классификации, который строит последовательность деревьев решений, каждое из которых исправляет ошибки предыдущего. Кластеризация, в отличие от классификации, не требует размеченной выборки и используется для поиска скрытых групп в данных.

Алгоритм k-means разделяет объекты на заданное число кластеров на основе расстояний между ними, а иерархическая кластеризация строит древовидную структуру вложенных групп. В рамках данной работы кластеризация не применяется, так как основное внимание уделено решению задачи классификации с помощью градиентного бустинга.

1.2.5 Примеры практического применения статистических методов

В ходе выполнения практических работ по дисциплине были реализованы и протестированы основные статистические методы на реальных данных. Описательная статистика применялась для расчёта среднего значения, медианы, моды, дисперсии и стандартного отклонения кредитного лимита клиентов. Методы проверки гипотез использовались для сравнения кредитных лимитов мужчин и женщин с помощью t-теста и критерия Манна-Уитни, а также для проверки независимости между полом и фактом дефолта с помощью хи-квадрат теста. Корреляционный анализ позволил выявить умеренную положительную связь между кредитным лимитом и суммой счета, а также сильную связь между счетами за соседние месяцы. Линейная регрессия показала, что кредитный лимит слабо зависит от возраста клиента. Множественная регрессия с категориальными переменными подтвердила, что наиболее сильное влияние на вероятность дефолта оказывает статус просрочки платежей за предыдущие месяцы. Эти примеры демонстрируют, как статистические методы применяются для анализа данных и подготовки основы для более сложных моделей, таких как градиентный бустинг.

1.3 Язык программирования R и его возможности для статистического анализа

1.3.1 Основные преимущества языка R

Язык программирования R является одним из наиболее распространённых инструментов для статистической обработки данных. Его главное преимущество заключается в специализации именно на задачах статистики и анализа данных. R распространяется с открытым исходным кодом, что означает бесплатное использование и возможность проверки реализованных алгоритмов. Язык обладает огромным количеством пакетов, которые охватывают практически все существующие методы статистического анализа и машинного обучения. Формульный синтаксис R делает код интуитивно понятным для исследователей, не имеющих глубоких навыков программирования. Кроме того, R обладает мощными встроенными средствами визуализации данных, позволяющими создавать публикационного качества графики. Среда разработки RStudio предоставляет удобный интерфейс для написания кода, отладки и оформления результатов

1.3.2 Обзор ключевых библиотек (tidyverse, ggplot2, dplyr, caret, forecast)

Экосистема R включает множество библиотек, расширяющих его возможности. Библиотека tidyverse представляет собой коллекцию пакетов для обработки и преобразования данных, объединённых общей философией. Пакет dplyr входит в состав tidyverse и предоставляет удобные функции для фильтрации, сортировки, группировки и агрегации данных. Пакет ggplot2

является основным инструментом для создания статической графики. Он реализует концепцию грамматики графики, позволяя строить сложные визуализации путём последовательного добавления слоёв. Пакет `caret` предоставляет унифицированный интерфейс к большому числу алгоритмов машинного обучения, включая классификацию, регрессию и настройку гиперпараметров. Пакет `forecast` предназначен для анализа и прогнозирования временных рядов.

1.3.3 Примеры использования R в обработке данных

В ходе выполнения практических работ были продемонстрированы возможности R для обработки и анализа данных. Загрузка данных из CSV-файла выполнялась с помощью функции `read_csv2` из пакета `readr`. Для просмотра структуры данных использовалась функция `head`, а для получения сводной статистики — функция `summary`. Фильтрация строк по условию выполнялась с помощью функции `filter` из пакета `dplyr`. Для расчёта описательных статистик, таких как среднее, медиана, дисперсия и стандартное отклонение, применялись встроенные функции `mean`, `median`, `var` и `sd`. Проверка гипотез проводилась с помощью функций `t.test` для t-теста, `wilcox.test` для критерия Манна-Уитни и `chisq.test` для хи-квадрат теста. Построение линейной регрессии выполнялось функцией `lm`, а множественной регрессии с категориальными переменными — с использованием той же функции после преобразования признаков в факторный тип. Визуализация результатов осуществлялась с помощью библиотеки `ggplot2`.

1.4 Программное обеспечение Glarus BI

1.4.1 Общая характеристика BI-системы

Glarus BI представляет собой систему бизнес-аналитики (Business Intelligence), предназначенную для визуального анализа данных и построения интерактивных отчётов. В отличие от языков программирования, Glarus BI ориентирован на пользователей, которые могут не иметь навыков написания кода. Основной интерфейс системы является визуальным: пользователь перетаскивает необходимые поля мышью, а система автоматически строит графики и таблицы. Glarus BI позволяет подключаться к различным источникам данных, включая файлы CSV, Excel и базы данных. Система подходит для быстрого исследовательского анализа, создания дашбордов и регулярной отчётности. В рамках учебного процесса Glarus BI используется для ознакомления с принципами работы BI-систем и сравнения их с программными подходами к анализу данных.

1.4.2 Основные функциональные возможности (импорт данных, визуализация, анализ)

Glarus BI предоставляет набор функций для полного цикла работы с данными. Импорт данных возможен из файлов различных форматов, а также из внешних баз данных. После загрузки система позволяет выполнять фильтрацию строк по заданным условиям, удалять пропуски и дубликаты, а также создавать новые вычисляемые столбцы. Для визуализации данных доступны различные типы графиков: столбчатые диаграммы, гистограммы, линейные графики, диаграммы рассеяния, тепловые карты и древовидные карты. Все графики являются интерактивными: пользователь может изменять цвета, применять фильтры, масштабировать отдельные области. Для агрегации данных доступны такие функции, как расчёт суммы, среднего значения, минимума, максимума и

количества записей. Результаты анализа могут быть экспортированы в форматы PDF, HTML и другие.

1.4.3 Примеры использования Glarus BI для анализа данных.

В ходе выполнения практических работ были решены типовые задачи с использованием Glarus BI. Выполнена загрузка набора данных из CSV-файла через интерфейс системы. Проведена фильтрация данных по условию, например, отобраны строки с определённым значением категориального признака. Рассчитано среднее значение числового столбца с помощью встроенной функции агрегации. Построена столбчатая диаграмма для визуализации распределения категориальных переменных. Создана гистограмма для анализа распределения числового признака. Настроены интерактивные фильтры, позволяющие динамически изменять отображаемые данные без повторной загрузки. Выполнена древовидная карта для отображения долей различных категорий в общем объёме. Эти примеры демонстрируют, что Glarus BI позволяет быстро выполнять базовые операции анализа без написания программного кода.

1.5 Сравнение возможностей R и Glarus BI

1.5.1 Где R удобнее (гибкость, мощность анализа, поддержка сложных

R удобнее в ситуациях, требующих гибкости и высокой мощности анализа. При работе со сложными статистическими моделями, такими как градиентный

бустинг, многомерная регрессия или анализ временных рядов, возможности R значительно превосходят функциональность BI-систем. R позволяет реализовывать любые алгоритмы обработки данных, поскольку пользователь самостоятельно пишет код. Это особенно важно при необходимости нестандартных преобразований или реализации новых методов. R также удобнее при работе с очень большими объёмами данных, где BI-системы могут работать медленно. Кроме того, R обеспечивает полную воспроизводимость анализа, так как весь процесс описан в виде скрипта, который можно повторно запустить в любой момент. Автоматизация регулярных отчётов также реализуется проще средствами R с использованием RMarkdown

1.5.2 Где Glarus BI удобнее (интерактивные отчёты, простота, использования)

Glarus BI удобнее в задачах, требующих быстрого визуального исследования данных и создания интерактивных отчётов. Для пользователей, не владеющих программированием, Glarus BI предоставляет интуитивно понятный интерфейс, где действия выполняются мышью без написания кода. Создание простых графиков и таблиц в Glarus BI занимает значительно меньше времени, чем написание соответствующего кода на R. Интерактивные дашборды с возможностью фильтрации и динамического изменения данных в Glarus BI строятся без дополнительных усилий, тогда как в R для создания аналогичных интерактивных элементов потребуется подключение специальных библиотек. Glarus BI также удобен для первичного знакомства с данными, быстрой проверки гипотез и оперативного получения ответов на простые аналитические вопросы

1.5.3 Возможность совместного использования инструментов

R и Glarus BI не являются взаимоисключающими, а могут успешно дополнять друг друга в рамках единого аналитического процесса. Сложная предобработка данных и построение статистических моделей могут выполняться в R, где для этого имеются все необходимые средства. Затем результаты анализа в виде обработанных данных или итоговых таблиц могут быть экспортированы в Glarus BI для визуализации и создания интерактивных дашбордов. Такой подход объединяет гибкость и мощность R с удобством и наглядностью BI-системы. Кроме того, отчёты, подготовленные в R с помощью RMarkdown, могут содержать ссылки на дашборды Glarus BI, а визуализации из Glarus BI могут встраиваться в итоговые документы. Совместное использование двух инструментов позволяет оптимально распределять задачи: всё, что требует сложных вычислений, выполняется в R, а всё, что связано с интерактивным просмотром и презентацией результатов, переносится в Glarus BI.

1.6 Предварительные выводы по главе 1

В первой главе курсовой работы были рассмотрены теоретические основы статистической обработки данных применительно к задаче выявления повышенного кредитного риска. Описана предметная область и показана значимость анализа данных в банковской сфере для прогнозирования дефолтов клиентов. Рассмотрены основные типы данных, используемые в задачах кредитного скоринга: числовые (возраст, кредитный лимит), категориальные (пол, семейное положение, образование).

Проведён обзор ключевых методов статистической обработки данных. Описательная статистика позволяет выполнить первичное обобщение данных через расчёт среднего, медианы, моды, дисперсии и стандартного отклонения. Методы проверки гипотез, включая t-тест, критерий Манна-Уитни и хи-квадрат тест, дают возможность формально оценить значимость различий между

группами клиентов и наличие связей между признаками. Корреляционный анализ и регрессионное моделирование используются для выявления зависимостей между переменными и построения прогнозных моделей. Методы классификации, в частности градиентный бустинг, являются основным инструментом для решения задачи отнесения клиентов к группам с низким или высоким кредитным риском.

Рассмотрены два инструмента для статистической обработки данных: язык программирования R и BI-система Glarus BI. R обладает высокой гибкостью, мощными статистическими библиотеками (tidyverse, ggplot2, dplyr) и полной воспроизводимостью анализа. Glarus BI предоставляет удобный визуальный интерфейс для быстрого исследовательского анализа и создания интерактивных дашбордов без необходимости написания кода. Сравнение инструментов показало, что R предпочтительнее для сложных вычислений, реализации нестандартных алгоритмов и автоматизации, тогда как Glarus BI удобен для быстрой визуализации и работы с данными пользователями без навыков программирования. Возможно совместное использование обоих инструментов, когда обработка данных и построение моделей выполняются в R, а визуализация результатов и создание отчётов реализуются в Glarus BI.

2 *Практическая реализация исследования*

2.1 Описание используемых данных

2.1.1 Источники данных (открытые наборы, экспериментальные, синтетические)

Для проведения исследования использовался набор данных Default of Credit Card Clients Dataset, размещённый в открытом репозитории UCI Machine Learning Repository. Данный набор данных был сформирован на основе информации о клиентах одного из коммерческих банков Тайваня и широко применяется в исследованиях, посвящённых анализу кредитных рисков и машинному обучению.

Набор данных содержит сведения о 30 000 клиентах, включая социально-демографические характеристики, размер кредитного лимита, историю платежей, суммы ежемесячных счетов и произведённых платежей за последние шесть месяцев. Исходный набор включает 24 признака и одну целевую переменную.

В рамках работы для построения регрессионной модели градиентного бустинга в качестве прогнозируемой переменной использовался показатель LIMIT_BAL, характеризующий размер кредитного лимита клиента.

Источник данных: UCI Machine Learning Repository. Default of Credit Card Clients Dataset [Электронный ресурс]. — URL: <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients> (дата обращения: 20.03.2026).

2.1.2 Структура и характеристики данных (числовые, категориальные, временные ряды)

Набор данных содержит 30 000 наблюдений и 25 переменных. В соответствии с классификацией, используемой в задаче кредитного скоринга, переменные делятся на следующие типы:

Числовые непрерывные: целевая кредитный лимит (LIMIT_BAL), возраст (AGE), суммы счетов за последние 6 месяцев (BILL_AMT1 – BILL_AMT6), суммы платежей за последние 6 месяцев (PAY_AMT1 – PAY_AMT6).

Категориальные: пол (SEX), образование (EDUCATION), семейное положение (MARRIAGE).

Порядковые (ordinal): статус оплаты за предыдущие месяцы (PAY_0, PAY_2 ... PAY_6), где отрицательные значения означают досрочную оплату, 0 — оплату в срок, а положительные — задержку на соответствующее число месяцев.

Бинарная переменная: default.payment.next.month (1 — дефолт в следующем месяце, 0 — отсутствие дефолта)

```

> df <- read_csv("C:/Users/APche/Documents/МИРЭА/R/Курсы/UCI_Credit_Card.csv")
Rows: 30000 Columns: 25
— Column specification —
Delimiter: ","
dbl (25): ID, LIMIT_BAL, SEX, EDUCATION, MARRIAGE, AGE, PAY_0, PAY_2, PAY_3, P...

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
>
> # просмотр первых строк
> head(df)
# A tibble: 6 × 25
  ID LIMIT_BAL SEX EDUCATION MARRIAGE AGE PAY_0 PAY_2 PAY_3 PAY_4 PAY_5
  <dbl>   <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1     1    20000     2       2       1    24     2     2    -1    -1    -2
2     2   120000     2       2       2    26    -1     2     0     0     0
3     3    90000     2       2       2    34     0     0     0     0     0
4     4    50000     2       2       1    37     0     0     0     0     0
5     5    50000     1       2       1    57    -1     0    -1     0     0
6     6    50000     1       1       2    37     0     0     0     0     0
# i 14 more variables: PAY_6 <dbl>, BILL_AMT1 <dbl>, BILL_AMT2 <dbl>,
#   BILL_AMT3 <dbl>, BILL_AMT4 <dbl>, BILL_AMT5 <dbl>, BILL_AMT6 <dbl>,
#   PAY_AMT1 <dbl>, PAY_AMT2 <dbl>, PAY_AMT3 <dbl>, PAY_AMT4 <dbl>,
#   PAY_AMT5 <dbl>, PAY_AMT6 <dbl>, default.payment.next.month <dbl>
>

```

Рисунок 2.1 – Загрузка датасета в R

2.1.3 Предварительная обработка данных (заполнение пропусков, фильтрация, преобразование)

Предварительная обработка включала следующие этапы (полный код представлен в листинге А.1 Приложения А):

Проверка пропусков: в исходном наборе данных пропущенные значения отсутствовали, что было подтверждено функциями `is.na()` в R и `isnull().sum()` в Python.

Кодирование категориальных переменных: переменные SEX, EDUCATION, MARRIAGE и PAY_0 были преобразованы в факторный тип в R (`as.factor`) и в категориальный тип в Python (`astype('category')`). Для множественной регрессии были созданы думми-переменные.

Масштабирование: для метода k-ближайших соседей (KNN) и кластеризации выполнена стандартизация числовых признаков с помощью `scale()` в R и `StandardScaler` в Python, так как эти методы чувствительны к масштабу данных.

Разделение выборки: для задач классификации данные были разделены на обучающую (70%) и тестовую (30%) выборки с использованием стратифицированного метода. Применение функции `createDataPartition()` из пакета `caret` гарантирует сохранение исходной пропорции классов (дефолт/не дефолт) в обеих выборках, что критически важно при работе с несбалансированными данными.

2.2 Исследовательский анализ данных (EDA – Exploratory Data Analysis)

2.2.1. Визуализация распределений




Рисунок 2.2 – Распределение кредитного лимита на R




Рисунок 2.3 – Распределение возраста в датасете на R




Рисунок 2.4 – Распределение кредитного лимита по полу 1-мужчины 2-женищны

2.2.2. Корреляционный анализ (корреляционные матрицы, значимость корреляции)

Корреляционный анализ проводился с использованием коэффициента корреляции Пирсона (для линейных связей) и Спирмена (для ранговых). Результаты:

Таблица 2.1 – Результаты корреляционного анализа признаков

Переменная X	Переменная Y	r Пирсона	r Спирмена
AGE	LIMIT_BAL	0.1447	0.1325
AGE	BILL_AMT1	0.0562	0.0451
LIMIT_BAL	BILL_AMT1	0.2854	0.3218
LIMIT_BAL	default	-0.1535	-0.1562
BILL_AMT1	BILL_AMT2	0.8692	0.9015

Наиболее сильная корреляция обнаружена между счетами за соседние месяцы (BILL_AMT1 и BILL_AMT2), что логично и не приводит к мультиколлинеарности при включении в модель только одного из них. Связь кредитного лимита с возрастом слабая (0.14), что говорит о том, что возраст не является основным фактором при назначении лимита.




Рисунок 2.5 – Визуализация корреляционной матрицы

```

> pearson_corr <- cor(df, method = "pearson")
> spearman_corr <- cor(df, method = "spearman")
> cat("Корреляция Пирсона:\n")
Корреляция Пирсона:
> print(pearson_corr)


```

	ID	LIMIT_BAL	SEX	EDUCATION	MARRIAGE
ID	1.0000000000	0.02617916	0.0184974942	0.0391767348	-0.029079425
LIMIT_BAL	0.0261791577	1.00000000	0.0247552351	-0.2191606982	-0.108139410
SEX	0.0184974942	0.02475524	1.0000000000	0.0142319362	-0.031388840
EDUCATION	0.0391767348	-0.21916070	0.0142319362	1.0000000000	-0.143464340
MARRIAGE	-0.0290794253	-0.10813941	-0.0313888401	-0.1434643404	1.0000000000
AGE	0.0186777345	0.14471280	-0.0908736465	0.1750606615	-0.414169918
PAY_0	-0.0305749323	-0.27121433	-0.0576428789	0.1053639979	0.019917190
PAY_2	-0.0112148683	-0.29638210	-0.0707710032	0.1215655525	0.024199067
PAY_3	-0.0184935538	-0.28612295	-0.0660960564	0.1140249029	0.032687673
PAY_4	-0.0027348898	-0.26746001	-0.0601732384	0.1087934562	0.033121549
PAY_5	-0.0221992319	-0.24941139	-0.0550638850	0.0975201606	0.035629170
PAY_6	-0.0202701341	-0.23519540	-0.0440077882	0.0823159864	0.034344766
BILL_AMT1	0.0193886739	0.28542986	-0.0336418696	0.0235811807	-0.023471802
BILL_AMT2	0.0179818975	0.27831436	-0.0311834722	0.0187487708	-0.021601780
BILL_AMT3	0.0243540500	0.28323578	-0.0245633117	0.0130024007	-0.024909451
BILL_AMT4	0.0403506029	0.29398762	-0.0218796791	-0.0004513453	-0.023343847
BILL_AMT5	0.0167053032	0.29556234	-0.0170051802	-0.0075665030	-0.025393398
BILL_AMT6	0.0167296183	0.29038895	-0.0167331263	-0.0090989547	-0.021206825
PAY_AMT1	0.0097424435	0.19523592	-0.0002424546	-0.0374561839	-0.005979000
PAY_AMT2	0.0084061203	0.17840795	-0.0013909097	-0.0300381866	-0.008092703
PAY_AMT3	0.0391505355	0.21016675	-0.0085966249	-0.0399431409	-0.003541352
PAY_AMT4	0.0077931297	0.20324241	-0.0022289715	-0.0382181661	-0.012659279
PAY_AMT5	0.0006521878	0.21720243	-0.0016671618	-0.0403584549	-0.001204757
PAY_AMT6	0.0029997807	0.21959537	-0.0027660223	-0.0371999031	-0.006640942
default.payment.next.month	-0.0139519548	-0.15351988	-0.0399605777	0.0280060777	-0.024339216
	AGE	PAY_0	PAY_2	PAY_3	PAY_4
ID	0.01867773	-0.03057493	-0.01121487	-0.018493554	-0.002734890
LIMIT_BAL	0.14471280	-0.27121433	-0.29638210	-0.286122954	-0.267460010

Рисунок 2.6 – Расчет коэффициентов корреляции на R

2.2.3. Выявление выбросов и трендов (поиск аномалий)

Выявление выбросов проводилось с помощью визуального анализа боксплотов и расчета z-оценок. Боксплоты для переменных BILL_AMT1 показали наличие значительного количества точек выше верхнего «уса» (выбросов). Эти значения не являются ошибками — они отражают реальное экономическое поведение (например, крупные покупки или досрочное погашение больших сумм). В рамках данного исследования эти выбросы не удалялись, так как они несут полезную информацию о платежеспособности клиентов.



**Рисунок 2.7 – Боксплот выбросы переменной BILL_AMT1 в зависимости от дефолта 1-
дефолт 0-отсутствие**

Сравнение средних значений показателей BILL_AMT1–BILL_AMT6 для групп клиентов с дефолтом и без дефолта выявило устойчивые различия в уровне задолженности. В группе клиентов, допустивших дефолт, средние суммы счетов на протяжении рассматриваемого периода выше, чем в группе добросовестных заёмщиков. Это позволяет предположить, что величина накопленной задолженности является одним из факторов, связанных с повышенным кредитным риском.




Рисунок 2.8 – Динамика средних значений BILL_AMT1–BILL_AMT6 в группах дефолта и отсутствия дефолта

2.3 Применение методов статистического анализа

2.3.1. Описательная статистика (средние, дисперсия, стандартное отклонение).

```
> summary(df$LIMIT_BAL)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
10000  50000 140000 167484 240000 1000000
> # Расчёт моды
> library(modeest)
> mode_value <- mfv(df$LIMIT_BAL)
> print(paste("Мода:", mode_value))
[1] "Мода: 50000"
> # Дисперсия и стандартное отклонение
> variance <- var(df$LIMIT_BAL)
> std_dev <- sd(df$LIMIT_BAL)
> print(paste("Дисперсия:", variance))
[1] "Дисперсия: 16834455682.1573"
> print(paste("Стандартное отклонение:", std_dev))
[1] "Стандартное отклонение: 129747.661567202"
> |
```

Рисунок 2.9 – Расчет показателей на R

Для переменной LIMIT_BAL (кредитный лимит) были рассчитаны следующие показатели (значения идентичны в Python и R):

Таблица 2.2 — описательной статистики

Показатель	Значение
Среднее	167 484.3 руб.
Медиана	140 000 руб.
Мода	50 000 руб.
Дисперсия	1.683e+10
Стандартное отклонение	129 746 руб.

Медиана (140 000) значительно меньше среднего (167 484), что подтверждает правостороннюю асимметрию распределения. Мода 50 000 указывает на то, что наиболее часто банк назначает минимальный лимит.

2.3.2. Проверка гипотез (t-тест, хи-квадрат).

```
> t.test(df$LIMIT_BAL ~ df$SEX)

welch Two sample t-test

data: df$LIMIT_BAL by df$SEX
t = -4.2147, df = 23901, p-value = 2.51e-05
alternative hypothesis: true difference in means between group 1 and group 2 is not equal to 0
95 percent confidence interval:
 -9620.489 -3512.785
sample estimates:
mean in group 1 mean in group 2
 163519.8      170086.5
```

Рисунок 2.10 – T-test

```
t_stat, p_value = stats.ttest_ind(male, female)
print("t-статистика:", t_stat, "p-значение:", p_value)

... t-статистика: -4.288903937895566 p-значение: 1.8011800666712653e-05
```

Рисунок 2.11 – T-test

```
> chi_test <- chisq.test(table(df$SEX, df$`default.payment.next.month`))
> print(chi_test)

Pearson's Chi-squared test with Yates' continuity correction

data: table(df$SEX, df$default.payment.next.month)
X-squared = 47.709, df = 1, p-value = 4.945e-12
```

Рисунок 2.12 – Chi квадрат тест

Для проверки зависимости между полом клиента и фактом дефолта был использован критерий хи-квадрат Пирсона.

Нулевая гипотеза H_0 : пол клиента и факт дефолта независимы. Альтернативная гипотеза H_1 : между полом клиента и фактом дефолта существует статистически значимая связь. Уровень значимости принят равным $\alpha = 0,05$.

В результате теста получено значение $\chi^2 = 47,0$ при числе степеней свободы $df = 1$ и $p\text{-value} = 4 \cdot 10^{-12}$. Поскольку $p\text{-value} < 0,05$, нулевая гипотеза отвергается. Следовательно, между полом клиента и фактом дефолта существует статистически значимая связь.

2.3.3. Регрессионный анализ (модели прогнозирования)

Простая линейная регрессия (зависимость кредитного лимита от возраста):
Уравнение: $\text{LIMIT_BAL} = 95\,203 + 2037 \times \text{AGE}$
Коэффициент детерминации $R^2 = 0.021$ (очень слабая связь)
 $p\text{-value}$ модели $< 2.2e-16$ (статистически значима, но практическая значимость

низкая)

```
> model <- lm(LIMIT_BAL ~ AGE, data = df)
> > summary(model)
```

ошибка: неожиданный '>' в ">"

```
> summary(model)
```

call:

```
lm(formula = LIMIT_BAL ~ AGE, data = df)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-215751 -102237  -25197   71098  809062
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  95203.14    2948.19   32.29  <2e-16 ***
AGE           2036.92     80.41   25.33  <2e-16 ***
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Residual standard error: 128400 on 29998 degrees of freedom
Multiple R-squared:  0.02094,    Adjusted R-squared:  0.02091
F-statistic: 641.6 on 1 and 29998 DF,  p-value: < 2.2e-16
```

Рисунок 2.14 – Линейная Регрессии на R

Множественная линейная регрессия (прогнозирование вероятности дефолта, бинарная целевая переменная). Наиболее значимые факторы:

Таблица 2.3 —множественная регрессия

Фактор	Коэффициент	p-value	Влияние
PAY_0_3 (задержка 3 мес)	0.534	<0.001	+53.4% вероятности дефолта
PAY_0_7 (задержка 7 мес)	0.541	<0.001	+54.1% вероятности дефолта

Фактор	Коэффициент	p-value	Влияние
мес)			
PAY_0_2 (задержка 2 мес)	0.476	<0.001	+47.6%
EDUCATION_5	-0.127	<0.001	снижает риск на 12.7%
MARRIAGE_0	-0.140	0.006	снижает риск на 14.0%

R^2 модели = 0.192, что типично для скоринговых моделей с бинарным ответом.

```

> model <- lm(default.payment.next.month ~ LIMIT_BAL + AGE + BILL_AMT1 + PAY_AMT1 +
+           SEX + EDUCATION + MARRIAGE + PAY_0, data = df)
>
> summary(model)

Call:
lm(formula = default.payment.next.month ~ LIMIT_BAL + AGE + BILL_AMT1 +
    PAY_AMT1 + SEX + EDUCATION + MARRIAGE + PAY_0, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-0.81219 -0.17208 -0.13342 -0.03322  1.12635

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.467e-01  1.354e-02  18.217 < 2e-16 ***
LIMIT_BAL    -3.339e-07  2.021e-08 -16.525 < 2e-16 ***
AGE           5.031e-04  2.758e-04   1.824 0.068139 .
BILL_AMT1     2.119e-07  3.584e-08   5.913 3.40e-09 ***
PAY_AMT1     -7.540e-07  1.336e-07  -5.642 1.70e-08 ***
SEX2          -2.295e-02  4.458e-03  -5.148 2.65e-07 ***
EDUCATION0    -1.729e-01  9.986e-02  -1.731 0.083400 .
EDUCATION2     6.294e-03  5.063e-03   1.243 0.213799
EDUCATION3    -1.353e-03  6.930e-03  -0.195 0.845185
EDUCATION4    -1.038e-01  3.388e-02  -3.065 0.002182 **
EDUCATION5    -1.268e-01  2.269e-02  -5.590 2.30e-08 ***
EDUCATION6    -4.985e-02  5.251e-02  -0.949 0.342455
MARRIAGE0     -1.398e-01  5.108e-02  -2.736 0.006219 **
MARRIAGE2     -2.170e-02  4.984e-03  -4.353 1.34e-05 ***
MARRIAGE3     1.063e-03  2.110e-02   0.050 0.959805
PAY_0-2       -1.875e-02  8.718e-03  -2.151 0.031473 *
PAY_00        -7.183e-02  6.597e-03 -10.889 < 2e-16 ***
PAY_01         1.446e-01  8.053e-03  17.955 < 2e-16 ***
PAY_02         4.756e-01  9.357e-03  50.832 < 2e-16 ***
PAY_03         5.340e-01  2.162e-02  24.699 < 2e-16 ***
PAY_04         4.498e-01  4.330e-02  10.388 < 2e-16 ***
PAY_05         2.704e-01  7.357e-02   3.676 0.000238 ***
PAY_06         3.151e-01  1.128e-01   2.794 0.005208 **
PAY_07         5.406e-01  1.247e-01   4.335 1.46e-05 ***
PAY_08         3.431e-01  8.594e-02   3.993 6.55e-05 ***
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3733 on 29975 degrees of freedom
Multiple R-squared:  0.1916,    Adjusted R-squared:  0.191
F-statistic: 296.1 on 24 and 29975 DF,  p-value: < 2.2e-16

```

Рисунок 2.15 – Множественная Регрессия на R

В дополнение к логистической регрессии была построена регрессионная модель градиентного бустинга для прогнозирования кредитного лимита клиента (LIMIT_BAL). В качестве факторов использовались социально-демографические характеристики клиентов, история платежей и финансовые показатели. Построение модели осуществлялось с использованием алгоритма Gradient Boosting Regressor, основанного на последовательном обучении

ансамбля деревьев решений. Каждое последующее дерево минимизирует ошибки предыдущих моделей, что позволяет постепенно повышать точность прогнозирования.




Рисунок 2.16 – Анализ сходимости

Таблица 2.4 — Зависимость RMSE от количества деревьев

Количество деревьев	RMSE
10	110708
25	101165
50	97289
75	96195
100	95660
150	95660
200	95660
300	95660.30

Анализ сходимости модели градиентного бустинга показал, что увеличение числа деревьев приводит к снижению среднеквадратической ошибки прогнозирования. Наибольшее улучшение качества наблюдается на начальных этапах обучения: при увеличении числа деревьев с 10 до 100 значение RMSE

уменьшилось с 110708 до 95660. Дальнейшее увеличение числа деревьев до 150–300 не привело к заметному улучшению результата, что свидетельствует о достижении устойчивого состояния модели и её сходимости. Для рассматриваемой задачи оптимальным оказалось использование около 100 деревьев, поэтому в дальнейших экспериментах использовалось это значение.

Таблица 2.5 – Влияние параметра *learning rate* на качество модели градиентного бустинга

Learning Rate	RMSE
0.05	97338.91
0.10	95584.85
0.20	94829.33



Рисунок 2.17 – Влияние *learning rate*

Исследование влияния параметра *learning rate* показало устойчивое улучшение качества модели при увеличении скорости обучения от 0,05 до 0,20.

Минимальная ошибка прогнозирования была достигнута при значении параметра 0,20.

Таблица 2.6 – Влияние глубины дерева на качество модели градиентного бустинга

Глубина дерева	RMSE
1	99176
3	95560
5	94854
7	94357.48
10	93837.57
12	93897.71

Анализ сходимости модели по глубине деревьев




Рисунок 2.18 – Анализ глубины деревьев

Таким образом, исследование влияния глубины деревьев показало устойчивое улучшение качества модели при увеличении. В рамках проведённого эксперимента оптимальным оказалось значение глубины, равное 12.

2.4 Машинное обучение в анализе данных

2.4.1 Классификация данных (логистическая регрессия)

Построена модель бинарной классификации для прогнозирования дефолта. Метрики качества (Python и R дали идентичные результаты):

Таблица 2.7 Сравнительная таблица метрик

Метрика	Логистическая регрессия (Python/R)
Accuracy	~0.82 / ~0.82
Precision	~0.65 / ~0.65
Recall	~0.35 / ~0.35
AUC	~0.72 / ~0.72

Несмотря на достаточно высокие значения Accuracy и Precision, модель характеризуется сравнительно низким Recall, что ограничивает её практическую применимость в задачах кредитного скоринга. В условиях управления кредитным риском пропуск потенциальных дефолтов является более критичной ошибкой, чем ложное отнесение клиента к группе риска. Поэтому результаты логистической регрессии могут рассматриваться как базовый уровень качества для последующего сравнения с более сложными моделями машинного обучения.




Рисунок 2.19 – ROC-AUC логистической регрессии

Площадь под ROC-кривой (AUC) составила 0,72. Полученное значение превышает 0,5, соответствующее случайному угадыванию, что свидетельствует о наличии у модели способности различать клиентов, склонных и не склонных к дефолту. Согласно общепринятой интерпретации, значение AUC в диапазоне 0,7–0,8 характеризует качество классификации как удовлетворительное.

Таким образом, логистическая регрессия демонстрирует приемлемую способность к разделению классов, однако значение $AUC = 0,72$ указывает на наличие потенциала для дальнейшего повышения качества прогнозирования за счёт применения более сложных алгоритмов машинного обучения, включая градиентный бустинг.

2.4.2. Кластеризация (K-means, иерархическая кластеризация)

Выполнена кластеризация клиентов на 3 группы. Кластер 1: молодые клиенты, низкий кредитный лимит, своевременная оплата. Кластер 2: средний возраст и лимит, самая многочисленная группа. Кластер 3: старшие клиенты, высокий лимит, часто задерживают платежи — группа повышенного кредитного риска.




Рисунок 2.20 – Выбор кол-ва кластеров с помощью метода локтя

Дополнительно была выполнена иерархическая кластеризация, результаты которой представлены в виде дендрограммы.




Рисунок 2.21 – Дендрограмма иерархической кластеризации

Данный метод позволил визуализировать структуру данных и взаимное расположение групп клиентов. Результаты кластеризации позволяют выделить группы клиентов со схожими характеристиками кредитного поведения. Выделенные кластеры могут использоваться банком для сегментации клиентской базы, оценки уровня риска и разработки различных стратегий кредитования для отдельных групп клиентов.

2.5 Визуализация данных

2.5.1. Визуализация в R (ggplot2, plotly)



Рисунок 2.22 – График k-means в R

2.5.2. Интерактивные дашборды в Glarus BI




Рисунок 2.23 – Древовидная карта доли дефолтов в разрезе категориальных признаков в glarus BI




Рисунок 2.24 – Кол во дефолтов по возрасту в glarus BI

2.5.3. Сравнение методов визуализации

R и Glarus BI дополняют друг друга в задачах визуализации данных. R с пакетом ggplot2 обеспечивает максимальную гибкость и высокое качество графиков для публикаций, но требует написания кода. Glarus BI позволяет создавать интерактивные дашборды без программирования, что удобно для быстрого исследовательского анализа и работы с бизнес-пользователями. Для сложных статистических визуализаций, таких как корреляционные матрицы или дендрограммы, предпочтительнее использовать R. При этом результаты анализа из R могут быть экспортированы в Glarus BI для построения интерактивных отчётов и презентации результатов широкой аудитории.

2.6 Предварительные выводы по разделу 2

Во втором разделе курсовой работы была выполнена практическая реализация исследования на основе открытого набора данных о клиентах банка. Проведён исследовательский анализ данных, включающий визуализацию распределений, корреляционный анализ и выявление выбросов и трендов. Применены методы описательной статистики, проверки гипотез (t-тест, хи-квадрат) и регрессионного анализа. Построены модели машинного обучения (логистическая регрессия, градиентный бустинг) и выполнена кластеризация клиентов методом K-means, которая позволила выделить группу повышенного риска. Визуализация результатов выполнена как в R, так и в Glarus BI, что позволило сравнить возможности двух инструментов. Полученные результаты подтверждают, что наибольшее влияние на вероятность дефолта оказывает статус просрочки платежей за предыдущие месяцы.

3 *Автоматизация и отчетность в анализе данных*

3.1 Генерация отчетов в R

3.1.1 Обоснование необходимости автоматизации отчетов

Ручное формирование отчётов требует много времени и приводит к ошибкам при повторном обновлении данных. Автоматизация позволяет один раз настроить процесс, после чего отчёт генерируется заново за секунды при любом изменении исходных данных.

3.1.2 Использование RMarkdown для создания отчетов

Для автоматизации формирования отчётности в работе использовалась технология RMarkdown. Данный инструмент позволяет объединять текстовое описание исследования, программный код на языке R, таблицы и графики в одном документе. При компиляции документа код выполняется автоматически, а результаты вычислений подставляются в итоговый отчёт. Пример структуры файла RMarkdown приведён в листинге Д.1. После компиляции файла формируется отчёт, содержащий результаты анализа данных, статистические показатели и визуализации.

3.1.3 Экспорт отчетов в PDF, HTML, Word

Созданный отчёт можно экспортировать в несколько форматов. PDF подходит для печати и официальной сдачи, HTML — для публикации в интернете, Word — для дальнейшего редактирования коллегами. Код автоматического формирования отчёта средствами пакета rmarkdown приведён в листинге Д.2.

Отчет

Sasha

2026-06-09

R Markdown

T# Общая информация

В отчёте представлены результаты анализа кредитного риска клиентов банка.

```
summary(df)
```

```
##           ID           LIMIT_BAL           SEX
## Min.      :    1   Min.      : 10000   1:11888
## 1st Qu.: 7501   1st Qu.:  50000   2:18112
## Median :15000   Median : 140000
## Mean    :15000   Mean    : 167484
## 3rd Qu.:22500   3rd Qu.: 240000
## Max.    :30000   Max.    :1000000
##
## EDUCATION MARRIAGE           AGE
## 1:10585   1:13659   Min.      :21.00
## 0:   14   0:   54   1st Qu.:28.00
## 2:14030   2:15964   Median :34.00
## 3: 4917   3:  323   Mean    :35.49
## 4:   123                      3rd Qu.:41.00
## 5:   280                      Max.    :79.00
## 6:    51
##           PAY_0           PAY_2
## 0           :14737   Min.      :-2.0000
## -1          : 5686   1st Qu.: -1.0000
## 1           : 3688   Median :  0.0000
## -2          : 2759   Mean    : -0.1338
## 2           : 2667   3rd Qu.:  0.0000
## 3           :  322   Max.      :  8.0000
## (Other):    141
##           PAY_3           PAY_4
## Min.      :-2.0000   Min.      :-2.0000
## 1st Qu.: -1.0000   1st Qu.: -1.0000
## Median :  0.0000   Median :  0.0000
```

Рисунок 3.1 – Пример созданного отчета с помощью Rmarkdown

3.2 Формирование интерактивных отчетов в Glarus BI

3.2.1 Различие между статичными и интерактивными отчетами

Статичный отчёт фиксирует данные на момент создания, его нельзя изменить. Интерактивный позволяет пользователю самому применять фильтры, выбирать категории и детализировать информацию в реальном времени.

3.2.2 Создание дашбордов в Glarus BI

В Glarus BI дашборд собирается через визуальный интерфейс без кода. Данные загружаются из файла, после чего поля перетаскиваются мышью на область построения графиков. Настраиваются фильтры, цвета и типы диаграмм.

3.2.3 Экспорт отчетов в Glarus BI

Готовый дашборд можно экспортировать в PDF для печати или в HTML для распространения в виде веб-страницы. Экспорт сохраняет все настройки и фильтры, но интерактивность в PDF не работает.

3.3 Сравнение инструментов R и Glarus BI

3.3.1 Анализ сильных и слабых сторон инструментов

R силён в гибкости, статистических расчётах и автоматизации, но требует навыков программирования. Glarus BI удобен для быстрой визуализации и работы с данными без кода, но проигрывает в сложных вычислениях и кастомизации.

3.3.2 Возможности интеграции R и Glarus BI

Предобработка данных и сложное моделирование выполняются в R, а результат экспортируется в Glarus BI для построения интерактивных дашбордов. Это позволяет объединить мощь статистического анализа с удобством визуализации.

3.3.3 Применимость инструментов для различных типов задач

R подходит для научных исследований, глубокого анализа и построения прогнозных моделей. Glarus BI — для бизнес-отчётности, мониторинга показателей и презентации результатов широкой аудитории без навыков программирования.

3.4 Предварительные выводы по главе 3

В третьей главе рассмотрены инструменты автоматизации аналитической отчётности. R с RMarkdown обеспечивает полную воспроизводимость и гибкость, а Glarus BI позволяет создавать интерактивные дашборды без программирования. Интеграция обоих инструментов даёт оптимальный

результат: сложные расчёты в R, наглядная презентация в Glarus BI. Выбор зависит от конкретной задачи и уровня подготовки пользователя.

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсовой работы была разработана регрессионная модель градиентного бустинга на основе открытого набора данных о клиентах банка. Проведённый исследовательский анализ данных позволил выявить основные закономерности в структуре данных, включая влияние финансовых показателей и истории платежей на характеристики клиентов. Реализованная модель продемонстрировала удовлетворительное качество прогнозирования, а анализ её сходимости показал, что такие параметры, как количество деревьев, скорость обучения и глубина деревьев, оказывают существенное влияние на качество модели.

Также в работе были рассмотрены инструменты статистической обработки данных — язык программирования R и BI-система Glarus BI.

Полученные результаты подтверждают возможность применения методов машинного обучения и статистического анализа для исследования данных клиентов банка и могут быть использованы при решении прикладных задач в финансовой сфере.

СПИСОК ИСТОЧНИКОВ

- 1.1 UCI Machine Learning Repository: Default of Credit Card Clients Dataset [Электронный ресурс]. — URL: <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients> (дата обращения: 20.03.2026).
- 1.2 Методические указания к выполнению курсовой работы по дисциплине «Языки программирования для статистической обработки данных» / сост. С.М. Трушин. — М.: РТУ МИРЭА, 2025. — 45 с.
- 1.3 Yeh I.-C., Lien C.-H. The Comparisons of Data Mining Techniques for the Predictive Accuracy of Probability of Default of Credit Card Clients // Expert Systems with Applications. — 2009. — Vol. 36, No. 2. — P. 2473–2480.
- 1.4 Халеева, Е.П. Анализ данных средствами языка R: учебное пособие / Е.П. Халеева, М.А. Аль-Ханани, М.Н. Лютикова. — Саратов: Вузовское образование, 2022. — 71 с.
- 1.5 Маркова, С.В. Анализ данных на языке R (с практикумом): учебник / С.В. Маркова. — М.: КноРус, 2023. — 218 с.
- 1.6 Митина, О.А. Языки программирования для статистической обработки данных (R): учебное пособие / О.А. Митина, И.А. Юрченков. — М.: МИРЭА, 2020. — 189 с.
- 1.7 Царькова, Е.Г. Применение методов искусственного интеллекта при анализе статистической информации / Е.Г. Царькова // Безопасность. Управление. Искусственный интеллект. — 2025. — Т. 2, № 2(2). — С. 26–31.
- 1.8 Лаврушин О. И. Банковское дело : учебник / О. И. Лаврушин, Н. Е. Бровкина, Н. И. Валенцева [и др.] ; под ред. О. И. Лаврушина. — Москва : КноРус, 2020. — 630 с.

- 1.9 Лаврушин О. И. Модели и технологии банковской деятельности : учебник / О. И. Лаврушин, И. И. Васильев, А. Е. Ушанов ; под ред. О. И. Лаврушина. — Москва : КноРус, 2021. — 180 с.
- 1.10 Лаврушин О. И. Ведение расчетных операций : учебник / О. И. Лаврушин, О. С. Рудакова, О. М. Маркова [и др.] ; под ред. О. И. Лаврушина. — Москва : КноРус, 2022. — 245 с.
- 1.11 Ланц Б. Машинное обучение на R: экспертные техники для прогностического анализа / Б. Ланц ; пер. с англ. — СПб. : Питер, 2020. — 464 с. ISBN 978-5-4461-1512-9.
- 1.12 Наумов В. Н. Анализ данных и машинное обучение. Методы и инструментальные средства : учебное пособие / В. Н. Наумов. — Москва : Дело (РАНХиГС), 2020. — 260 с. ISBN 978-5-89781-667-5.
- 1.13 Мыльников Л. А. Статистические методы интеллектуального анализа данных / Л. А. Мыльников. — СПб. : БХВ-Петербург, 2020. — 240 с. ISBN 978-5-9775-6733-6.
- 1.14 Богатырев С. Ю. (ред.). Машинное обучение в финансах : учебник. — Москва : Прометей, 2024. — 224 с. ISBN 978-5-00172-572-5.
- 1.15 Воронцов К. В. Математические методы обучения по прецедентам (теория машинного обучения). — Москва : МЦНМО, 2023. — 424 с.
- 1.16 Кремер Н. Ш. Теория вероятностей и математическая статистика : учебник для вузов / Н. Ш. Кремер. — Москва : ЮНИТИ-ДАНА, 2023. — 551 с.
- 1.17 Орлов А. И. Прикладная статистика : учебник / А. И. Орлов. — Москва : Юрайт, 2022. — 579 с.
- 1.18 Айвазян С. А. Анализ данных и прикладная статистика : учебник / С. А. Айвазян, В. С. Мхитарян. — Москва : Юрайт, 2021. — 490 с.
- 1.19 Тавасиев А. М. Банковское дело : управление кредитной организацией : учебное пособие / А. М. Тавасиев. — Москва : Дашков и К°, 2022. — 640 с.

- 1.20 Махмудов Б. С. Влияние технологий машинного обучения для задач кредитного скоринга // Тенденции развития науки и образования. — 2023. — № 104. — DOI: 10.18411/trnio-12-2023-779.
- 1.21 Сорокин А. С. Comparative analysis of the use of statistical modeling and machine learning for credit risk assessing in microfinance organizations // Economic Bulletin. — 2024. — Vol. 3, № 2. — С. 51–65.

ПРИЛОЖЕНИЯ

Приложение А — Обработка набора данных

Приложение Б — Листинги исследовательского анализа данных

Приложение В — Листинги модели градиентного бустинга

Приложение Г — Листинги построения моделей машинного обучения

Приложение Д — Листинги формирования отчёта RMarkdown

Приложение А

Обработка набора данных

Листинг А.1 — обработка набора данных

```
df <- read_csv(my_path)
# Проверка наличия пропущенных значений
any(is.na(df))
colSums(is.na(df))

# Структура данных
str(df)
# Сводная статистика для проверки корректности данных
summary(df)

df$SEX <- as.factor(df$SEX)
df$EDUCATION <- as.factor(df$EDUCATION)
df$MARRIAGE <- as.factor(df$MARRIAGE)
df$PAY_0 <- as.factor(df$PAY_0)
df$default.payment.next.month <- as.factor(df$default.payment.next.month)
df_numeric <- df[, sapply(df, is.numeric)]
df_numeric <- df_numeric[, !names(df_numeric) %in% c("ID", "default.payment.next.month")]
df_scaled <- scale(df_numeric)

set.seed(42)
trainIndex <- createDataPartition(df$default.payment.next.month,
                                   p = 0.7,
                                   list = FALSE)

train_data <- df[trainIndex, ]
test_data <- df[-trainIndex, ]
```


Приложение Б

Исследовательский анализ данных (EDA – Exploratory Data Analysis)

Листинг Б.1 — Построение корреляционной матрицы

```
pearson_corr <- cor(df, method = "pearson")
spearman_corr <- cor(df, method = "spearman")
print(pearson_corr)
print(spearman_corr)
library(corrplot)
corrplot(pearson_corr, method = "color", tl.cex = 0.6)
```

Листинг Б.2 — Распределения, выбросы

```
library(ggplot2)

ggplot(df, aes(x = LIMIT_BAL)) +
  geom_histogram(bins = 50)

ggplot(df, aes(x = AGE)) +
  geom_histogram(bins = 30)

ggplot(df, aes(x = factor(SEX), y = LIMIT_BAL)) +
  geom_boxplot()

ggplot(df, aes(x = factor(default.payment.next.month), y = BILL_AMT1)) +
  geom_boxplot()
ggplot(df, aes(x = factor(SEX), y = LIMIT_BAL, fill = factor(SEX))) +
  geom_boxplot() +
  scale_x_discrete(labels = c("Мужчины", "Женщины"))

ggplot(df, aes(x = factor(default.payment.next.month), y = BILL_AMT1)) +
  geom_boxplot() +
  scale_x_discrete(labels = c("Нет дефолта", "Дефолт"))

default_client <- df[df$default.payment.next.month == 1, ][1, ]

# Средние суммы счетов для клиентов с дефолтом
default_mean <- c(
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT1, na.rm =
TRUE),
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT2, na.rm =
TRUE),
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT3, na.rm =
TRUE),
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT4, na.rm =
TRUE),
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT5, na.rm =
TRUE),
  mean(df[df$default.payment.next.month == 1, ]$BILL_AMT6, na.rm = TRUE)
)
# Средние суммы счетов для клиентов без дефолта
```

Продолжение Листинга Б.2 — Распределения, выбросы

```
# Средние суммы счетов для клиентов без дефолта
nondefault_mean <- c(
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT1, na.rm = TRUE),
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT2, na.rm = TRUE),
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT3, na.rm = TRUE),
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT4, na.rm = TRUE),
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT5, na.rm = TRUE),
  mean(df[df$default.payment.next.month == 0, ]$BILL_AMT6, na.rm = TRUE)
)

months <- c(
  "BILL_AMT1",
  "BILL_AMT2",
  "BILL_AMT3",
  "BILL_AMT4",
  "BILL_AMT5",
  "BILL_AMT6"
)

plot(
  1:6,
  nondefault_mean,
  type = "b",
  pch = 16,
  xaxt = "n",
  xlab = "Период наблюдения",
  ylab = "Средняя сумма счета",
  main = "Средние суммы счетов по группам клиентов"
)

axis(1, at = 1:6, labels = months)

lines(
  1:6,
  default_mean,
  type = "b",
  pch = 17
)

legend(
  "topright",
  legend = c("Нет дефолта", "Дефолт"),
  pch = c(16, 17)
)

grid()
```

Приложение В

Листинги модели градиентного бустинга

Листинг В.1 — Анализ влияния количества деревьев

```
library(gbm)

trees <- c(10, 25, 50, 75, 100, 150, 200, 300)

rmse_values <- numeric(length(trees))

for (i in seq_along(trees)) {

  model <- gbm(
    LIMIT_BAL ~ .,
    data = train_data,
    distribution = "gaussian",
    n.trees = trees[i],
    interaction.depth = 3,
    shrinkage = 0.1,
    n.minobsinnode = 10,
    verbose = FALSE
  )

  pred <- predict(
    model,
    newdata = test_data,
    n.trees = trees[i]
  )

  rmse_values[i] <- sqrt(
    mean((test_data$LIMIT_BAL - pred)^2)
  )
}

tree_results <- data.frame(
  Trees = trees,
  RMSE = rmse_values
)

print(tree_results)

plot(
  trees,
  rmse_values,
  type = "b",
  pch = 19,
  xlab = "Количество деревьев",
  ylab = "RMSE",
  main = "Анализ сходимости по количеству деревьев"
)

grid()
```

Листинг В.2 — Анализ влияния скорости обучения (Learning Rate)

```
learning_rates <- c(0.05, 0.10, 0.20)

rmse_lr <- numeric(length(learning_rates))

for (i in seq_along(learning_rates)) {

  model <- gbm(
    LIMIT_BAL ~ .,
    data = train_data,
    distribution = "gaussian",
    n.trees = 100,
    interaction.depth = 3,
    shrinkage = learning_rates[i],
    n.minobsinnode = 10,
    verbose = FALSE
  )

  pred <- predict(
    model,
    newdata = test_data,
    n.trees = 100
  )

  rmse_lr[i] <- sqrt(
    mean((test_data$LIMIT_BAL - pred)^2)
  )
}

learning_results <- data.frame(
  LearningRate = learning_rates,
  RMSE = rmse_lr
)

print(learning_results)

plot(
  learning_rates,
  rmse_lr,
  type = "b",
  pch = 19,
  xlab = "Learning Rate",
  ylab = "RMSE",
  main = "Влияние скорости обучения на качество модели"
)

grid()
```

Листинг В.3 — Анализ влияния глубины деревьев

```
depths <- c(1, 3, 5, 7, 10, 12)

rmse_depth <- numeric(length(depths))

for (i in seq_along(depths)) {

  model <- gbm(
    LIMIT_BAL ~ .,
    data = train_data,
    distribution = "gaussian",
    n.trees = 100,
    interaction.depth = depths[i],
    shrinkage = 0.1,

```

Продолжение Листинга В.3 — Анализ влияния глубины деревьев

```
n.minobsinnode = 10,
verbose = FALSE
)

pred <- predict(
  model,
  newdata = test_data,
  n.trees = 100
)

rmse_depth[i] <- sqrt(
  mean((test_data$LIMIT_BAL - pred)^2)
)
}

depth_results <- data.frame(
  Depth = depths,
  RMSE = rmse_depth
)

print(depth_results)

plot(
  depth_results$Depth,
  depth_results$RMSE,
  type = "b",
  pch = 19,
  lwd = 2,
  xlab = "Глубина дерева",
  ylab = "RMSE",
  main = "Анализ сходимости модели по глубине деревьев"
)

grid()
```

Приложение Г

Листинги раздела «Машинное обучение в анализе данных»

Листинг Г.1 — Логистическая регрессия

```
# Логистическая регрессия
model_logit <- glm(default.payment.next.month ~ .,
                  data = train_data,
                  family = binomial)
summary(model_logit)
# Предсказание вероятностей
pred_prob <- predict(model_logit, newdata = test_data, type = "response")
pred_class <- ifelse(pred_prob > 0.5, 1, 0)

# Матрица ошибок
confusionMatrix(as.factor(pred_class), test_data$default.payment.next.month)
```

Листинг Г.2 — KMeans

```
# K-means кластеризация
set.seed(42)
# Используем масштабированные числовые признаки (без целевой переменной)
X_scaled <- scale(train_data[, sapply(train_data, is.numeric)])
X_scaled <- X_scaled[, !colnames(X_scaled) %in% c("ID",
"default.payment.next.month")]
# Кластеризация на 3 кластера
kmeans_model <- kmeans(X_scaled, centers = 3, nstart = 10)
clusters <- kmeans_model$cluster
centroids <- kmeans_model$centers
# Добавляем кластеры в данные
train_data$cluster <- as.factor(clusters)
```

Листинг Г.3 — Иерархическая кластеризация

```
# Иерархическая кластеризация
set.seed(42)

# Берём первые 1000 наблюдений для лучшей визуализации
X_scaled_sample <- X_scaled[1:1000, ]

# Матрица расстояний
dist_matrix <- dist(X_scaled_sample)

# Иерархическая кластеризация (метод Ward)
hc <- hclust(dist_matrix, method = "ward.D2")

# Дендрограмма
plot(hc, main = "Дендрограмма иерархической кластеризации",
     xlab = "Наблюдения", ylab = "Расстояние")

# Отсечение на высоте 25 (выделение 3 кластеров)
abline(h = 25, col = "red", lty = 2)

# Выделение кластеров
cluster_groups <- cutree(hc, k = 3)
table(cluster_groups)
```

Приложение Д

Листинги раздела «Формирования отчёта RMarkdown »

Листинг Д.1 — содержание файла credit_report.Rmd Rmarkdown

```
---
title: "Отчет"
author: "Sasha"
date: "2026-06-09"
output: html_document
---

```{r setup, include=FALSE}
knitr::opts_chunk$set(echo = TRUE)
```

## R Markdown

# Общая информация

В отчёте представлены результаты анализа кредитного риска клиентов банка.

```{r}
summary(df)
```

# Распределение кредитного лимита

```{r}
hist(
 df$LIMIT_BAL,
 main = "Распределение кредитного лимита",
 xlab = "LIMIT_BAL"
)
```
```

Листинг Д.2 — создание отчета с помощью Rmarkdown

```
rmarkdown::render("credit_report.Rmd")
```